

Problem Tanımı: E-Ticaret Dinamik Fiyatlandırma Optimizasyonu

Bu çalışma, bir e-ticaret satıcısının sınırlı stok kısıtı altında toplam kârını maksimize etmek için geliştirdiği bir otonom karar destek sistemini konu almaktadır.

1. Problemin Doğası ve Hedef

E-ticaret ortamında fiyat, satış hacmi ve kâr marjı arasındaki temel dengeleyicidir. Problemin temel unsurları şunlardır:

- Fiyat Esnekliği:** Fiyatın pazar referans fiyatına göre çok yüksek belirlenmesi durumunda satış olasılığı düşmekte ve elde kalan ürünler için depo maliyeti oluşmaktadır.
- Kâr Kaybı:** Fiyatın çok düşük belirlenmesi durumunda ise potansiyel kârdan feragat edilmektedir.
- Dönemsel Talep Dalgalanmaları:** Anneler Günü, okulların kapanış dönemi ve yaz sezonu gibi yüksek yoğunluklu dönemler müşteri talep olasılığını doğrudan etkilemektedir.
- Hedef:** Stok tükenene kadar geçen sürede, takvimsel dalgalanmaları da hesaba katarak toplam kârı maksimize edecek "en iyi" fiyatlandırma politikasını öğrenmektir.

2. Markov Karar Süreci (MDP) ve Q-Table Yapısı

Problemin Q-Learning ile çözülebilmesi için pazar dinamikleri sonlu ve ayrık parçalara bölünerek bir Q-Tablosu oluşturulmuştur:

A. Durum Uzayı (State - s)

Ajan, her adımda envanter ve pazar durumunu 6 farklı kombinasyonda gözlemler:

- Kalan Stok:** [0-5 (Az), 6-15 (Orta), 16-35 (Çok)].
- Dönem Tipi:** Normal Dönem ve Yüksek Sezon / Yaz Dönemi (19. Hafta Anneler Günü ve 24. Hafta okul kapanış takvimini otomatik işler).

B. Aksiyon Uzayı (Action - a)

Ajanın her durumda seçebileceği 3 temel eylem bulunmaktadır:

- İndirim Yap:** Mevcut fiyatı %5 azalt.
- Sabit Tut:** Fiyatı değiştirme.
- Zam Yap:** Mevcut fiyatı %5 artır.

C. Ödül Mekanizması (Reward - r)

- Satış gerçekleşirse: + (Satış Fiyatı - Maliyet)
- Satış olmazsa: - (Depo Maliyeti)

3. Simülasyon ve Eğitim Parametreleri

Ajan, sentetik varsayımlar yerine **Google Drive üzerinde yer alan gerçek e-ticaret veri seti (OnlineRetail.csv)** üzerinden, akıllı sütun tespit motoru yardımıyla 20.000 veri döngüsü boyunca eğitilmiştir.

- **Talep Fonksiyonu:** Satış olasılığı, gerçek pazar fiyatı medyanı referans alınarak sigmoid fonksiyonu üzerinden dinamik olarak hesaplanmaktadır.

Hiperparametreler:

- **Öğrenme Oranı (alpha):** 0.15 (Ajanın yeni bilgiye ne kadar hızlı adapte olacağını belirler).
- **İndirim Faktörü (gamma):** 0.98 (Gelecekteki ödüllere verilen önemi temsil eder).
- **Keşif Politikası (epsilon):** 1.0 başlangıç değeriyle yavaşça azalan (decay: 0.9995) ϵ -greedy stratejisi.

Bu modelleme sayesinde ajan, hangi stok seviyesinde ve hangi dönemsel koşulda fiyatı ne kadar değiştirmesi gerektiğini gerçek Tüketici davranışlarından otonom olarak keşfetmektedir.

E-Ticaret Platformlarında Q-Öğrenme Tabanlı Dinamik Fiyatlandırma Optimizasyonu

Özet

Bu çalışma, değişken pazar koşulları, takvimsel özel günler ve sınırlı stok kısıtları altında bir e-ticaret ajanının toplam kârını maksimize etme problemini ele almaktadır. Geleneksel sabit fiyatlandırma modellerinin aksine, Pekiştirmeli Öğrenme (Reinforcement Learning) prensiplerine dayalı bir Q-Learning algoritması geliştirilmiştir. Google Drive entegrasyonu ile beslenen gerçek bir e-ticaret veri tabanında 20.000 iterasyon boyunca eğitilen ajan, mevsimselliği analiz ederek optimal fiyatlandırma stratejilerini otonom olarak keşfetmiştir.

Doğrulama aşamasında, soyut grafiklerin ötesine geçilerek envanter hareketlerini kutu bazlı ızgara (grid) sistemiyle görselleştiren **fiziksel bir otonom depo simülasyon motoru** sisteme entegre edilmiştir. Sonuçlar, ajanın maliyet bilinciyle hareket ederek zarar etmeden ve otonom mal kabul döngüleriyle stok erittiğini kanıtlamaktadır. Geliştirilen bu hareketli görsel çıktı, Base64 şifreleme yöntemiyle doğrudan proje dosyasına enjekte edilerek platform bağımsız kesintisiz çalışma altyapısına kavuşturulmuştur.

1. GİRİŞ

Dijital ticaretin hız kazanmasıyla birlikte, tüketicilerin fiyat duyarlılığı ve takvimsel özel günlerin (Anneler Günü, yaz sezonu başlangıcı vb.) getirdiği anlık talep dalgalanmaları kâr marjlarını doğrudan etkilemektedir. Sabit fiyatlandırma stratejileri, bu dinamik yapıda fırsat maliyetlerine veya stok birikmesine yol açmaktadır. Bu çalışmanın amacı, bir ajanın "deneme-yanılma" yoluyla en karlı fiyat seviyesini bulmasını ve stok durumuna göre otonom aksiyonlar almasını sağlamaktır. Çalışmada algoritmanın şeffaflığını ve karar mekanizmasını net bir şekilde gözlemleyebilmek adına Tabular Q-Learning yöntemi tercih edilmiştir.

2. METODOLOJİ

2.1. Ortam ve Veri Modellemesi

Gerçek dünya verilerindeki dönemsel karmaşıklığı simüle etmek amacıyla veri setindeki **InvoiceDate** sütunu üzerinden akıllı zaman filtreleri kurgulanmıştır. Satış olasılığı, fiyat esnekliği kurallarına dayalı sigmoid bazlı bir talep fonksiyonu ile tanımlanmış olup, hesaplama hatalarını önlemek adına girdi değerleri $[-50, 50]$ aralığında sınırlanmıştır (clipping).

Fiziksel envanter takibini görünür kılmak adına, soyut çizgiler yerine depodaki kutuların yığılmasını ve satış anında eksilmesini temsil eden 2 boyutlu bir grid matris simülasyonu inşa edilmiştir.

2.2. MDP ve Hiperparametreler

Çalışmada kullanılan Markov Karar Süreci (MDP) bileşenleri şunlardır:

- **Durum Uzayı (S):** 3 stok seviyesi ve 2 takvimsel dönem durumu (Normal, Yüksek Sezon) ile toplam 6 ayrı durum.
- **Aksiyon Uzayı (A):** Fiyatı %5 artırma, %5 düşürme veya sabit tutma.
- **Öğrenme Parametreleri:** Öğrenme oranı 0.15, indirim faktörü 0.98 olarak belirlenmiştir. Keşif oranı, 0.9995 katsayısı ile yavaşça azaltılarak ajanın geniş bir strateji yelpazesini taraması sağlanmıştır.

3. SONUÇLAR VE ANALİZ

3.1. Öğrenme Performansı ve Yakınsama

Öğrenme Eğrisi incelendiğinde, ajanın ilk aşamalarda yüksek varyanslı sonuçlar aldığı ve pazar fiyatını dengede tutmaya çalıştığı görülmektedir. Eğitim süreci sonunda trend çizgisinin kararlı bir duruş sergilediği gözlemlenmiştir. Bu durum, ajanın pazar dinamiklerini çözerek rassal kararlardan optimal stratejilere geçtiğini kanıtlamaktadır.

3.2. Strateji Matrisi (Q-Table) Analizi

Q-Table Isı Haritası, ajanın kazandığı tecrübeleri sayısal olarak özetler. Ajanın "Stok Çok / Yüksek Sezon" durumunda fiyat ayarlama eylemlerine verdiği ağırlıklar, pazar payını koruma ve özel gün talebini kâra çevirme stratejisinin başarıyla öğrenildiğini göstermektedir. Isı haritasındaki belirgin renk değişimleri, ajanın her durum için "dominant" bir strateji geliştirdiğini belgelemektedir.

3.3. Dinamik Kutu Tabanlı Depo Simülasyonu

Geliştirilen dinamik görselleştirme hücrelerinde, ajanın fiyat politikasıyla eş zamanlı olarak depodaki fiziksel kutuların azaldığı net bir şekilde gözlemlenmiştir. Stok seviyesi kritik eşik olan 5 kutunun altına indiğinde, sistem otonom mal kabul (tedarik) algoritmasını tetikleyerek depoya aniden 25 yeni kutu yerleştirmekte ve operasyonel devamlılığı hareketli olarak sergilemektedir. En kritik bulgu, ajanın fiyatı envanter hacmine göre kırarken asla maliyet sınırının altına düşürmemesidir. Bu, ajanın karsız satışlardan kaçınma yeteneğini temsil eder.

4. TARTIřMA

Yapılan 20.000 bölümlük gerçek veri tabanlı eğitim sonucunda ajanın pazar döngülerini başarıyla yönettiđi kaydedilmiştir. Ajanın stok miktarını ve takvimdeki kritik haftaları göz önüne alarak "fiyatı ne zaman deđiřtirmesi gerektiđini" otonom olarak keřfetmesi, Pekiřtirmeli Öğrenme yönteminin e-ticaret lojistiđi ve dinamik fiyatlandırma üzerindeki etkinliđini ortaya koymaktadır.

Hücre çıktılarına entegre edilen Pillow tabanlı sonsuz döngülü ($\$loop=0\$$) animasyon yapısı, projenin GitHub gibi platformlarda statik bir resim yerine yařayan bir simülasyon olarak sergilenmesine imkan tanımıştır. Gelecek çalışmalarda bu model, çoklu rakip davranışlarının da deđiřken olduđu çok ajanlı (Multi-Agent) senaryolarla genişletilebilir.